

DATA ESSENTIALS · DAE-FT-111

Pilotage des risques de chantier

Un moteur d'arbitrage prédictif pour concilier rentabilité, respect du planning et sobriété carbone sur les chantiers BTP.

AUTEURES

Arthy AROUL · Aurélie MAHE

PÉRIODE

24 Août – 04 Sept. 2026

DATASET

BIM-AI Integrated Dataset · Kaggle



« Peut-on prédire le niveau de risque chantier à partir des indicateurs opérationnels et environnementaux ? »

Contexte et enjeux



Le constat

- Chantiers exposés à de multiples facteurs de risque
- Ressources d'audit et de contrôle sécurité limitées
- Suivi encore largement manuel et réactif



L'opportunité

- Identifier en amont les chantiers les plus à risque
- Prioriser intelligemment audits et interventions
- Passer d'un pilotage à vue à un pilotage prédictif

Les acteurs concernés



Opérationnels

- Chefs de chantier
- Conducteurs de travaux
- Équipes techniques terrain



Financiers

- Maître d'ouvrage
- Entreprise / bureau d'études
- Assureurs & garants



Réglementaires

- Responsable HSE
- Autorités publiques
- Organismes de contrôle

Choix du dataset



Building Performance Dataset

ABANDONNÉ APRÈS EXPLORATION

- Données propres mais totalement synthétiques
- **Distribution trop uniforme**
- Variables pouvant répondre à la problématique



BIM-AI Integrated Dataset

DATASET RETENU

- Données propres mais synthétiques
- Distribution légèrement plus réaliste
- Variables pouvant répondre à la problématique

Le dataset en chiffres

1 000

Projets
(lignes)

28

Variables
(colonnes)

21

Colonnes
numériques

7



Colonnes
catégorielles




21 variables utiles retenues pour l'analyse et la modélisation

7 variables écartées (identifiants, dates brutes, doublons d'information)

Catégorisation des variables



Distribution du niveau de risque




Ce que révèle la répartition

- Classes déséquilibrées : 50% High, 34% Medium, 16% Low
- Bien plus de chantiers « High » que « Low » dans les données
- Distributions qui se chevauchent entre les classes
- Un déséquilibre à traiter avant toute modélisation



Planning et pression temporelle



Accident_Count selon le quartile de retard (Schedule_Deviation)




Questions posées

- Les chantiers en avance sont-ils aussi ceux qui ont le moins d'accidents ?



Effectifs et équipements



Safety_Risk_Score moyen selon Labor_Hours (8 tranches)




Questions posées

- Existe-t-il un seuil de main d'œuvre au-delà duquel le risque n'augmente plus ?



Dérives budgétaires et risques climatiques




Corrélation de Cost_Overrun avec planning et variables climatiques



Questions posées

- Le dépassement budgétaire est-il plus lié au planning qu'au climat ?


Un signal statistique très faible



Décisions prises

- Corrélation maximale trouvée : 0,07 (quasi nulle)
- Variables réparties étrangement uniformément entre Low / Medium / High
- Safety_Risk_Score retiré du modèle pour éviter tout biais de fuite de données
- Distribution du risque qui se chevauche fortement entre classes

Cible binaire opérationnelle



Ce que ça change

- Classification binaire de criticité, plus actionnable
- Medium redistribué selon Safety_Risk_Score
- Safety_Risk_Score ensuite retiré du modèle

Solutions de Machine Learning

ML 1



Logistic Regression

- Simplicité, rapidité, baseline
- Interprétabilité, coefficients
- Linéarité, signal faible
- Faible overfitting, référence

ML 2



Decision Tree

- Seuils, non-linéarité, règles
- Interactions, splits
- Interprétable, visuel
- Overfitting, instabilité

ML 3



Random Forest

- Stabilité, robustesse
- Non-linéarité, performance
- Class_weight, flexibilité
- Feature_importances



Logistic Regression — Baseline

0,41

F1-score macro

-0,06

MCC

65%




Accuracy



Confirme l'hypothèse d'un signal faiblement linéaire : le modèle peine à séparer les classes, cohérent avec les corrélations quasi nulles observées en EDA.



Logistic Regression — Tentatives d'Amélioration



Confirme l'hypothèse d'un signal faiblement linéaire : le modèle peine à séparer les classes, cohérent avec les corrélations quasi nulles observées en EDA.



Decision Tree — résultats

0,44

F1-score macro

-0,03

MCC

63%

Accuracy




Les règles de seuil captées par l'arbre n'apportent qu'un gain marginal — signe que la structure du signal n'est pas purement due à des effets de seuil simples.




Decision Tree — résultats

Matrice de Confusion - Baseline Decision Tree



Architecture du Decision Tree (Top 3 niveaux de décision)





Random Forest — résultats

0,56

F1-score macro

0,00

MCC

65%



Accuracy (tuned)



Meilleur F1 des trois modèles après SMOTE, GridSearchCV et ajustement du `class_weight` — mais un MCC proche de 0 nuance fortement cette amélioration apparente.



Random Forest — résultats



Métriques retenues



Recall (High)

Proportion de chantiers réellement critiques détectés



Precision

Évite de déclencher trop d'audits inutiles



F1-score

Équilibre entre precision et recall



F2-score

Donne plus de poids au recall qu'à la precision



ROC-AUC

Capacité à distinguer High / Low, indépendamment du seuil



MCC

Capacité à regarder les 4 cases symétriquement, utile en cas de déséquilibre des classes

Pistes d'Optimisation à explorer



SMOTE dosé

Sur-échantillonnage plus léger de la classe minoritaire



Redéfinition du class_weight

Ajuster finement l'équilibrage sans SMOTE



GridSearchCV élargi


Recherche plus fine des hyperparamètres optimaux




Suivi via le MCC

Adopter une métrique plus robuste au déséquilibre

Progression du F1-score



F1-score vs MCC



À retenir

- Le F1 progresse, mais le MCC reste proche de 0
- Le modèle ne fait quasiment pas mieux que le hasard
- Une lecture à une seule métrique aurait été trompeuse

Difficultés rencontrées



Données peu fiables

Un premier dataset finalement écarté
après exploration approfondie



Déséquilibre des classes

Bien plus de projets « High » que « Low »
→ risque d'overfitting



Corrélations quasi nulles

Presque aucune relation exploitable entre
variables et risque

Changement de dataset dès le départ — et le même problème de fond a resurgi sur le dataset finalement retenu.



Piste d'Amélioration

*Changer la matière
plutôt que complexifier le modèle*



WHAT'S NEXT ?

*« Quel coût sommes-nous prêts à accepter
pour réduire un risque d'accident grave
ou mortel ? »*



Any questions?

Merci de votre attention.